IESB

Pós Graduação em Inteligência Artificial

Disciplina: Estatística e Análise de dados

Docente: Mateus Mendelson Discente: Henrique Brandão

Credit card

```
import scipy
import numpy as np
import pandas as pd
import seaborn as sns
import scipy.stats as stats
import matplotlib.pyplot as plt

from seaborn_qqplot import pplot
from sklearn.utils import shuffle
from imblearn.over_sampling import SMOTE
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import train_test_split
from sklearn.metrics import confusion_matrix, classification_report
%config IPCompleter.use_jedi = False
```

```
In [2]: df = pd.read_csv('creditcard.csv')
```

%matplotlib notebook

In [3]: df.head()

| | Time | V1 | V2 | V3 | V4 | V 5 | V6 | V7 | |
|---|------|-----------|-----------|----------|-----------|------------|-----------|-----------|----|
| 0 | 0.0 | -1.359807 | -0.072781 | 2.536347 | 1.378155 | -0.338321 | 0.462388 | 0.239599 | 0 |
| 1 | 0.0 | 1.191857 | 0.266151 | 0.166480 | 0.448154 | 0.060018 | -0.082361 | -0.078803 | 0 |
| 2 | 1.0 | -1.358354 | -1.340163 | 1.773209 | 0.379780 | -0.503198 | 1.800499 | 0.791461 | 0 |
| 3 | 1.0 | -0.966272 | -0.185226 | 1.792993 | -0.863291 | -0.010309 | 1.247203 | 0.237609 | 0 |
| 4 | 2.0 | -1.158233 | 0.877737 | 1.548718 | 0.403034 | -0.407193 | 0.095921 | 0.592941 | -(|


5 rows × 31 columns

```
In [4]:
          def _isnull(df):
               for c in df.columns:
                   if df[pd.isnull(df[c])].shape[0] != 0:
                        print(f'# {c}: {cnt} rows')
          _isnull(df)
 In [5]:
          df['Class'].value counts()
                284315
                  492
           1
           Name: Class, dtype: int64
In [124]:
          print('Índice de fraudes: {:.2f}%'.format((492/284315)*100))
           Índice de fraudes: 0.17%
 In [6]:
          df['Amount'].describe()
           count
                   284807.000000
           mean
                      88.349619
                      250.120109
           std
           min
                        0.000000
           25%
                       5.600000
           50%
                       22.000000
           75%
                       77.165000
                    25691.160000
           max
           Name: Amount, dtype: float64
In [144]:
          legit = sum(df['Amount'][df['Class'] == 0])
          frd = sum(df['Amount'][df['Class'] == 1])
          legit, frd, legit - frd, legit/frd
           (25102462.039983638, 60127.96999999997, 25042334.06998364, 417.4839436618873)
In [143]:
          print('Percentual do montante fraudado: {:.2f}%'.format((frd/legit) '
           Percentual do montante fraudado: 0.24%
In [307]:
          q1 = 5.6
          q3 = 77.165
          iqr = q3 - q1
          inf = q1 - 1.5*iqr
          sup = q3 + 1.5*iqr
```

```
def not_outlier(x):
             if (x \ge \inf) and (x \le \sup):
                 return True
             else:
                 return False
In [311]:
         amount_sem_out = list(filter(not_outlier, df['Amount']))
In [316]:
         sns.boxplot(x=amount_sem_out, palette="Set3")
         plt.title('Gastos (sem outliers)')
         plt.xlabel('Valor')
         plt.show()
                                     Gastos (sem outliers)
                    0
                           25
                                  50
                                         75
                                                100
                                                       125
                                                              150
                                                                      175
                                             Valor
           1) Visualização do histograma de gastos geral do dataset (at-
           adequada do parâmetro bins)
```

```
In [297]:
          sns.histplot(data=df['Amount'], bins=100)
         plt.show()
           250000
           200000
           150000
         Count
           100000
            50000
                               5000
                                         10000
                                                   15000
                                                              20000
                                                                         25000
                                              Amount
            2) Visualização dos histogramas de gastos das transações fra
            transações não fraudulentas em separado (atente-se para ur
            parâmetro bins)
In [14]:
         # Legit
         df['Amount'][df['Class'] == 0].describe()
                  284315.000000
           count
                     88.291022
           mean
                     250.105092
           std
                      0.000000
           min
           25%
                      5.650000
           50%
                     22.000000
           75%
                     77.050000
                   25691.160000
           Name: Amount, dtype: float64
In [133]:
         sns.histplot(data=df['Amount'][df['Class'] == 0], bins=100)
          plt.title('Classe: 0')
```

```
plt.show()
                                                Classe: 0
            250000
            200000
            150000
            100000
             50000
                                 5000
                                            10000
                                                       15000
                                                                   20000
                                                                              25000
                                                 Amount
In [134]:
          # Fraud
          df['Amount'][df['Class'] == 1].describe()
                    492.000000
           count
                    122.211321
           mean
                    256.683288
            std
           min
                      0.000000
            25%
                      1.000000
            50%
                      9.250000
            75%
                    105.890000
                    2125.870000
           max
           Name: Amount, dtype: float64
In [135]:
          sns.histplot(data=df['Amount'][df['Class'] == 1], bins=80)
          plt.title('Classe: 1')
          plt.show()
                                                Classe: 1
```




3) Para cada histograma gerado, indique, utilizando QQ-Plot, adequa a ele e caracterize a distribuição (média e desvio pac

Vamos normalizar as distribuições, através da seguinte relação: z =


```
def normalizar_df(df, col: str):
    pop = df[col]
    media = df[col].mean()
    std = df[col].std()
    return (pop - media)/std
```

Geral

```
plt.ylabel('z-score')
plt.xlabel('std')
plt.show()
  Média: 88.35, desvio padrão: 250.12
```




- Legítima



```
In [197]:
    df_fraud = df['Amount'][df['Class'] == 1]
        fraud_media = df_fraud.mean()
        fraud_std = df_fraud.std()

        z_fraud = (df_fraud - fraud_media)/fraud_std

        print('Média: {:.2f}, desvio padrão: {:.2f}'.format(fraud_media, fraution fr
```



4) Realize um teste A/B da seguinte forma: separe, aleatoriar grupo A deve conter 50% das transações não fraudulentas e fraudulentas. O grupo B, por sua vez, deve conter os dados r dataset tivesse 100 transações (sendo 80 não fraudulentas e

A teria 40 transações não fraudulentas e 10 transações frauc quantidades se aplicariam ao grupo B). O grupo A deve ser o grupo B será o grupo que receberá a nova técnica de identificadulentas. Essa técnica consiste em: caso a transação pos igual a 122.20, ela deve ser classificada como fraudulenta. A nova técnica sobre a porcentagem de transações fraudulenta porcentagem das transações que realmente eram fraudulent classificadas como fraudulentas? A técnica aplicada no grupo grupo A?

```
sdf = shuffle(df[['Amount', 'Class']])
sdf.head()
```

| | Amount | Class |
|--------|--------|-------|
| 175842 | 1.51 | 0 |
| 182727 | 25.00 | 0 |
| 172416 | 42.00 | 0 |
| 16581 | 3.80 | 0 |
| 120017 | 0.01 | 0 |

(142403, 2)

```
In [154]:
          A['Class'].value_counts()
               142158
                  246
           Name: Class, dtype: int64
In [155]:
          perc_fraudes_em_A = (A['Class'].value_counts()[1]/A.shape[0]) * 100
          perc_fraudes_em_A
          print('Percentual de fraudes em A: {:.2f}%'.format(perc_fraudes_em_A
           Percentual de fraudes em A: 0.17%
In [156]:
          B['Class'].value_counts()
               142157
                  246
           Name: Class, dtype: int64
In [157]:
          perc_fraudes_em_B = (B['Class'].value_counts()[1]/B.shape[0]) * 100
          perc_fraudes_em_B
          print('Percentual de fraudes em B: {:.2f}%'.format(perc fraudes em B
           Percentual de fraudes em B: 0.17%
In [158]:
          def regra fraude(x):
              if x >= 122.20:
                  return 1
              else:
                  return 0
In [165]:
          B.head()
                  Amount Class Pred_regra
          163517 62.50
          70537
                  3.57
          9230
                  29.99
                                 0
          240317 550.00
                                 1
                           0
          93238
                  100.00
                                 0
                           0
In [160]:
         B['Pred_regra'] = B['Amount'].apply(regra_fraude)
In [163]:
          print(classification_report(y_true=B['Class'], y_pred=B['Pred_regra'
```

```
recall f1-score
                       precision
                                                   support
                           1.00
                                    0.83
                                             0.91
                                                    142157
                    0
                           0.00
                                    0.26
                                             0.01
                                                      246
                                             0.83
                                                   142403
              accuracy
                                    0.54
             macro avg
                           0.50
                                             0.46
                                                    142403
In [166]:
          print(confusion_matrix(y_true=B['Class'], y_pred=B['Pred_regra']))
           [[118429
                   23728]
               183
                      63]]
In [293]:
          _ = B[B['Class'] == 1].shape[0]
          print(f'Número de fraudes em B: {_}}')
          print('A regra aplicada classificou corretamente {:.2f}% das fraudes
           Número de fraudes em B: 246
           A regra aplicada classificou corretamente 0.26% das fraudes
            5) Realize o seguinte teste de hipótese: transações frauduler
            gasto, na média, maiores ou iguais a 122.20
In [204]:
          if (df[df['Class'] == 1]['Amount'].mean() - 122.2) >= 0:
              print('Hipótese verdadeira!')
          else:
              print('Hipótese falsa!')
           Hipótese verdadeira!
            6) Utilizando as classes LogisticRegression e SMOTE, realize ove
            modelo, relatando qual a porcentagem de transações fraudul
In [254]:
          df.head()
                        V1
                                  V2
                                           V3
                                                     V4
                                                              V5
                                                                        V6
                                                                                 V7
             Time
          0.0
                   -1.359807 -0.072781 2.536347 1.378155 -0.338321 0.462388
                                                                            0.239599
                                                                                     0
          1 0.0
                   1.191857
                             0.266151  0.166480  0.448154
                                                         0.060018
                                                                  -0.082361 -0.078803 0
          2 1.0
                   -1.358354 -1.340163 1.773209 0.379780
                                                         -0.503198 1.800499
                                                                            0.791461
                                                                                     0
                   -0.966272 -0.185226 1.792993 -0.863291 -0.010309 1.247203
          3 1.0
                                                                            0.237609
                                                                                     0
                   -1.158233 0.877737 1.548718 0.403034
                                                        -0.407193 0.095921
          4 2.0
                                                                            0.592941
                                                                                     -(
         5 rows × 31 columns
```

```
In [251]:
          df.shape, df.columns
            ((284807, 31),
            Index(['Time', 'V1', 'V2', 'V3', 'V4', 'V5', 'V6', 'V7', 'V8', 'V9', 'V10',
                   'V11', 'V12', 'V13', 'V14', 'V15', 'V16', 'V17', 'V18', 'V19', 'V20',
                   'V21', 'V22', 'V23', 'V24', 'V25', 'V26', 'V27', 'V28', 'Amount',
                   'Class'],
                  dtype='object'))
In [221]:
          df['Class'].value_counts()
           0
                284315
                   492
           Name: Class, dtype: int64
In [261]:
          x = df.drop(labels=['Time', 'Class'], axis=1)
          y = df['Class']
          x.shape, y.shape
           ((284807, 29), (284807,))
In [262]:
          oversample = SMOTE(random state=666)
In [263]:
          x_sm, y_sm = oversample.fit_resample(x, y)
          x_sm.shape, y_sm.shape
            ((568630, 29), (568630,))
In [266]:
          print(f'Porcentagem de dados de fraude: {100*sum(y_sm)/y_sm.shape[0]]
           Porcentagem de dados de fraude: 50.0%
In [272]:
          x_train, x_test, y_train, y_test = train_test_split(x_sm, y_sm, test_
          x_train.shape, y_train.shape, x_test.shape, y_test.shape
            ((426472, 29), (426472,), (142158, 29), (142158,))
In [278]:
          lr = LogisticRegression(max iter=1e5)
In [279]:
          lr.fit(x_train, y_train)
           LogisticRegression(max_iter=10000.0)
```

```
In [281]:
          pred = lr.predict(x_test)
In [282]:
          print(classification_report(y_true=y_test, y_pred=pred))
                        precision
                                    recall f1-score
                                                     support
                     0
                             0.94
                                      0.98
                                               0.96
                                                       71211
                             0.98
                                      0.94
                                               0.96
                                                       70947
                                               0.96
                                                      142158
               accuracy
              macro avg
                             0.96
                                      0.96
                                               0.96
                                                      142158
                                      0.96
           weighted avg
                             0.96
                                               0.96
                                                      142158
In [284]:
          print(confusion_matrix(y_true=y_test, y_pred=pred))
           [[69875 1336]
            [ 4471 66476]]
In [288]:
          print('A regressão classificou corretamente {:.2f}% das fraudes'.for
           A regressão classificou corretamente 98.03% das fraudes
 In [ ]:
```